Analytics für Entwickler

und alle anderen

Sebastian Schulthess

Professional Software Developer

8.1.2019

Agenda

- Was ist Machine Learning
- Wie funktioniert Machine Learning (Anwendung)

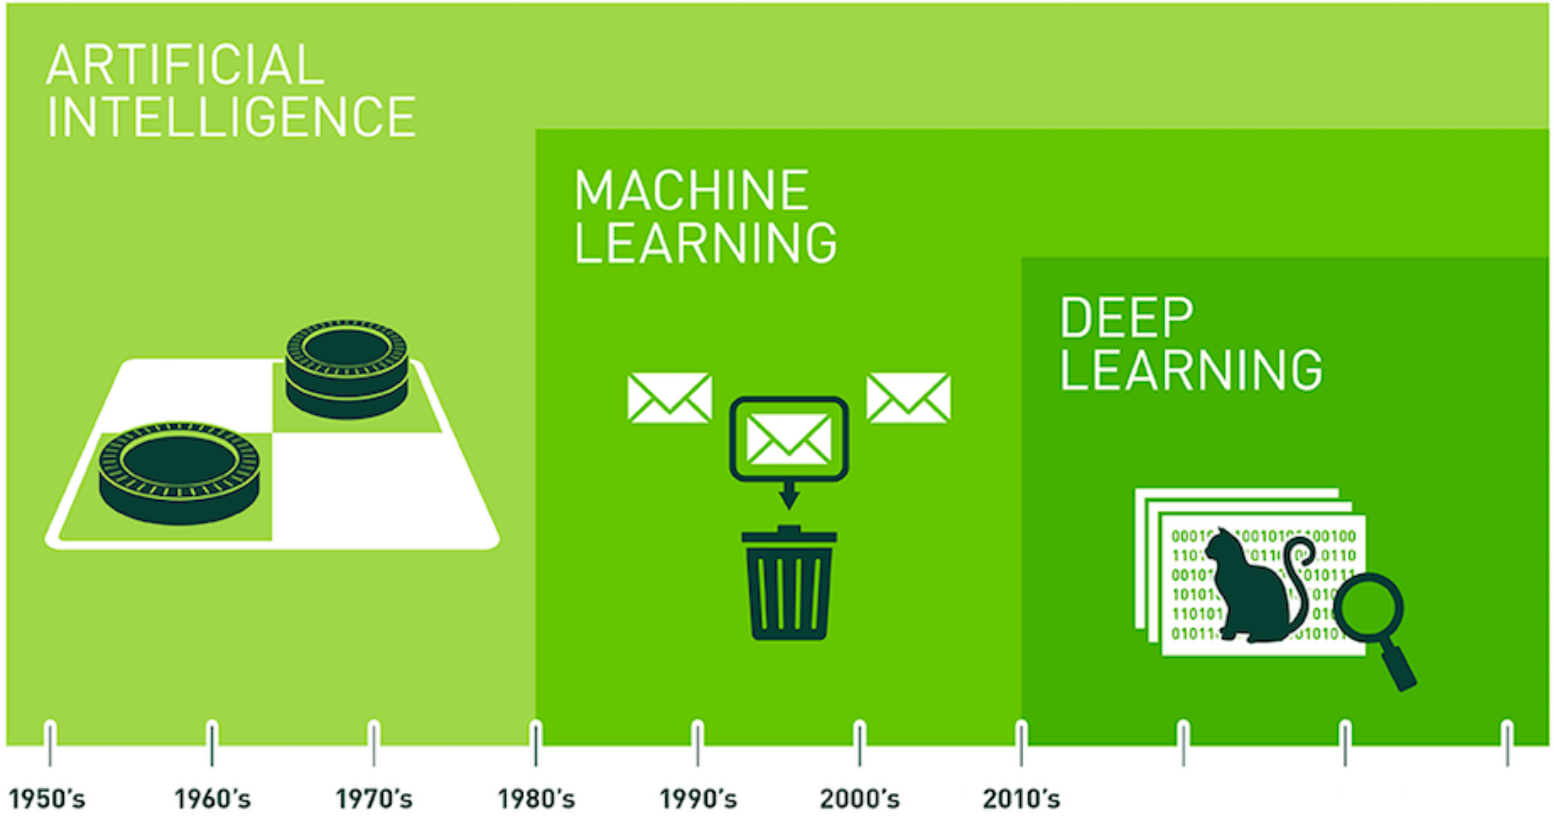
ARTIFICIAL INTELLIGENCE
MACHINE LEARNING
DEEP LEARNING
1950's
1960's
1970's
1980's
1990's
2000's
2010's

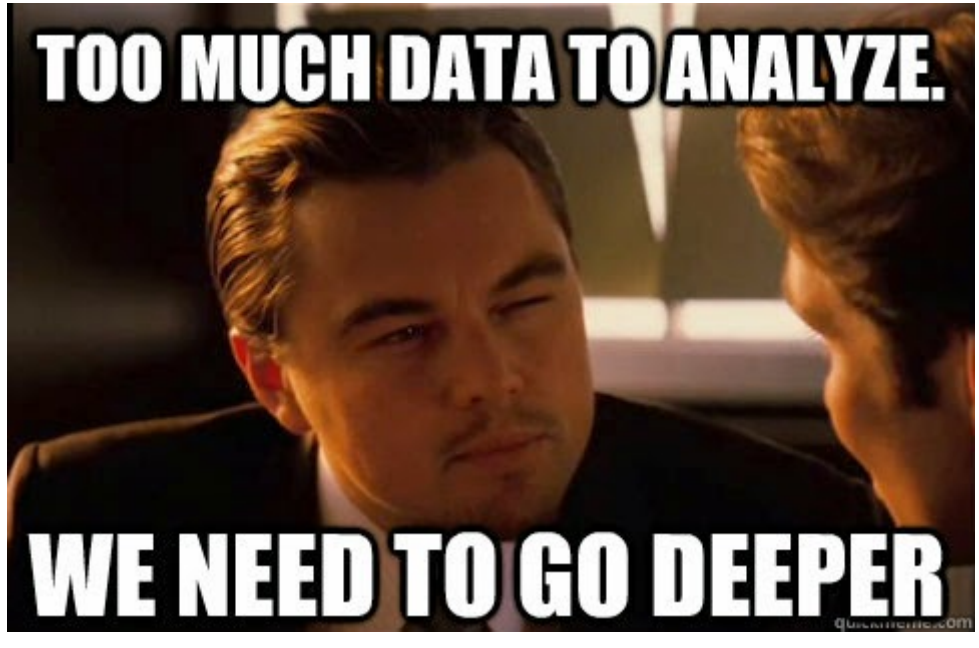
TOO MUCH DATA TO ANALYZE.
WE NEED TO GO DEEPER


WE'RE GONNA NEED
A GPU
imgflip.com

Deep Learning Beispiele

In [2]:
```
IFrame('https://zaidalyafeai.github.io/pix2pix/cats.html', width=1200, height=800)
```

Out[2]:

A simple implementation of the pix2pix paper on the browser using TensorFlow.js. Th
after you draw some edges. Make sure you run the model in your laptop as mobile d
current models. Use the mouse to draw. For detailed information about the implementat

— ZAID ALYAFEAI

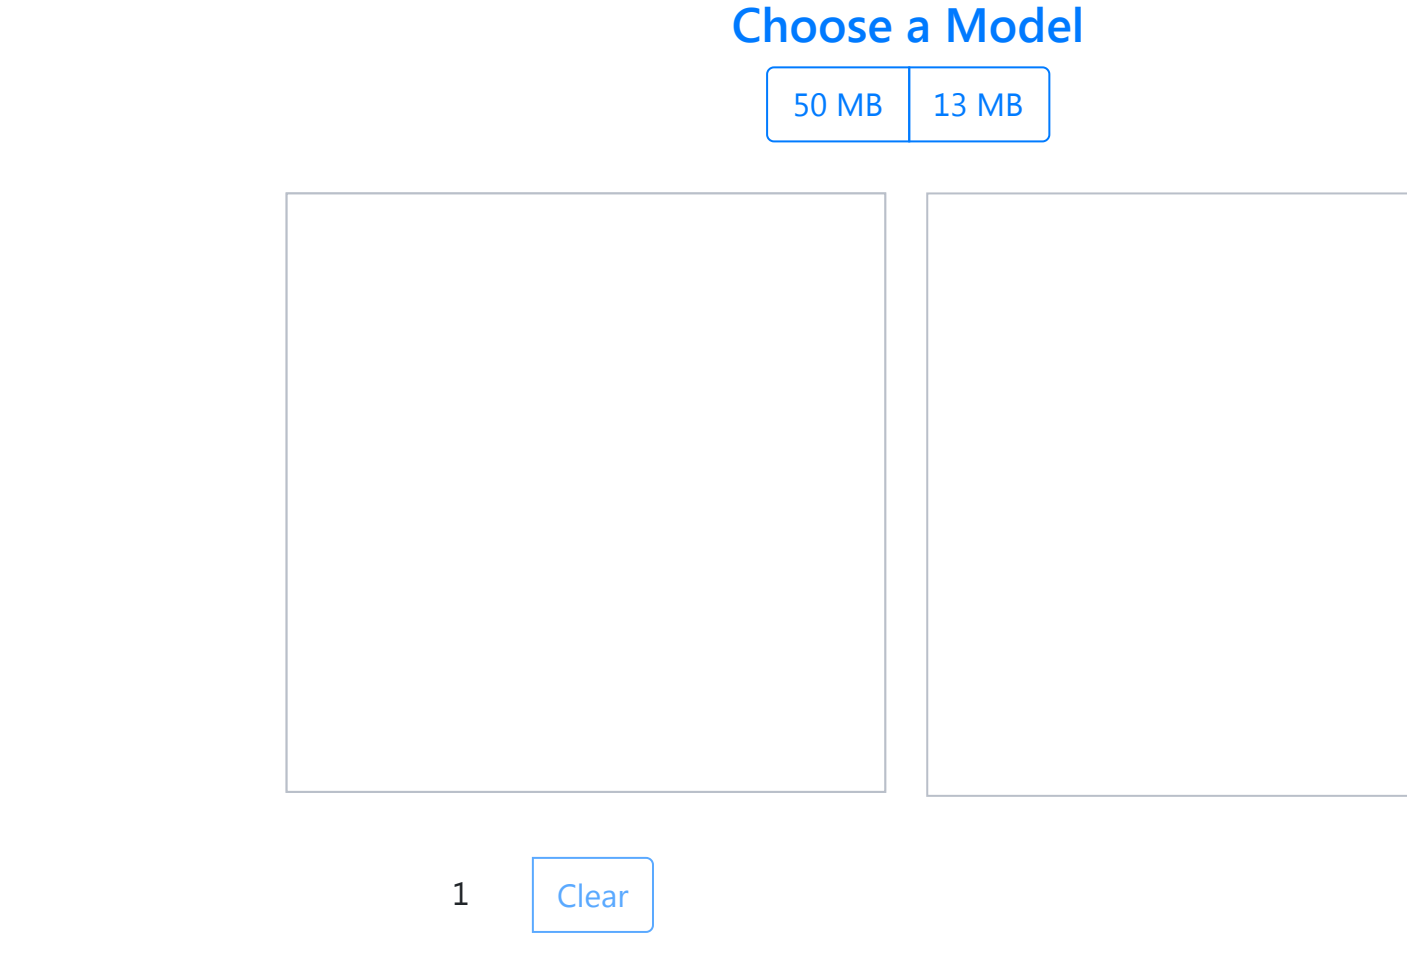

Deep Learning Beispiele

In [3]:
```
IFrame('https://www.deepl.com/translator', width=1200, height=800)
```

Out[3]:

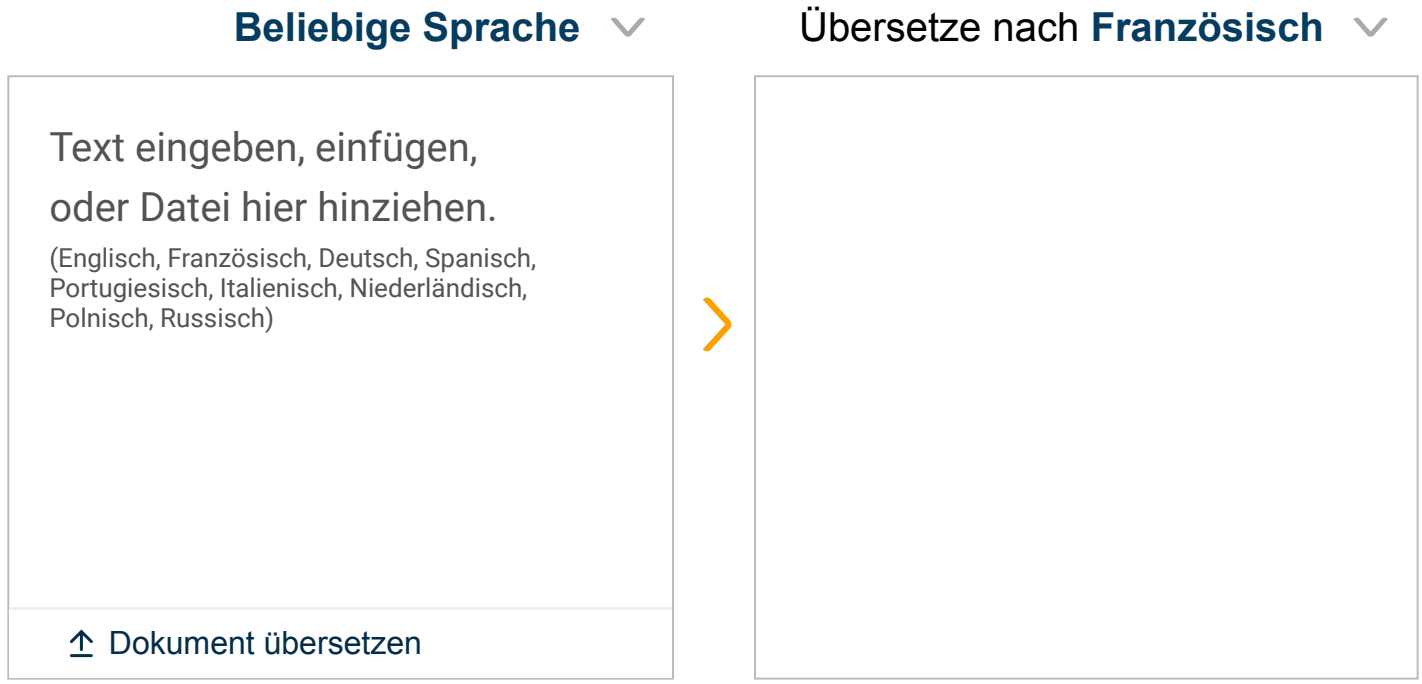

Halten Sie Ihre Texte vertraulich
Weiterlesen

Übersetzte Dokumente
bearbeiten
Weiterlesen

Erleben Sie DeepL in vollem

Umfang

Verwenden Sie
Übersetzungssoftware-Plugins

Machine Learning Definition

> *Machine learning (ML) is a category of algorithm that allows software applications to become more accurate in predicting outcomes without being explicitly programmed. The basic premise of machine learning is to build algorithms that can receive input data and use statistical analysis to* ***predict*** *an output while updating outputs as* ***new data*** *becomes available.*

source: https://searchenterpriseai.techtarget.com/definition/machine-learning-ML (https://searchenterpriseai.techtarget.com/definition/machine-learning-ML)

Was sind die beiden Hauptkategorien von Machine Learning?

Supervised learning: Vorhersage machen

Ziel: Für einen neuen Datensatz eine Vorhersage (Zuteilung oder Wert) machen.

- Zuteilung = Klassifikation, Wert = Regression

Unsupervised learning: Strukturieren der Daten

Ziel: Eine Struktur innerhalb der Daten extrahieren

- Es gibt keine "richtige Antwort"

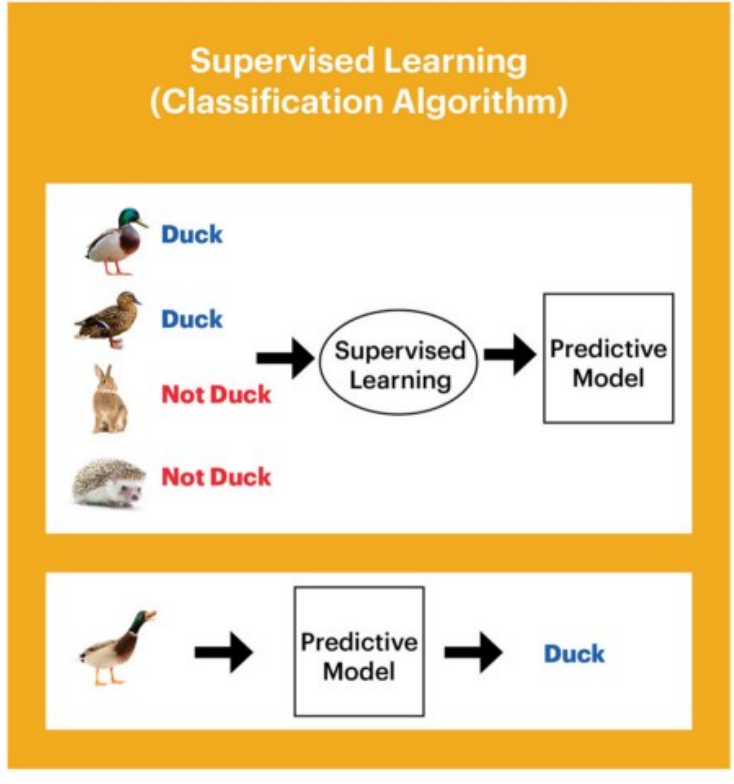

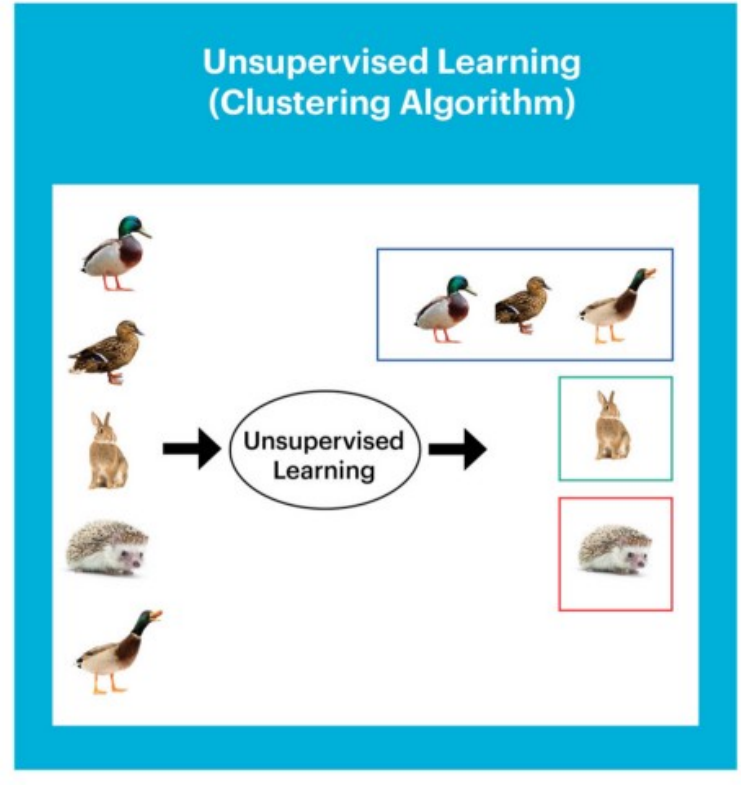

Western Digital.

Dieses Supervised Learning klingt gut, wie kann ich loslegen?

- Daten
- Fragestellung anhand der Daten
- Entwicklungsumgebung

In [4]:
```
print('python')
```

```
python
```

Titanic Datensatz

In [5]:
```
df_titanic  = pandas.read_excel('titanic.xls', 'titanic3', index_col=None, na_values=['NA'])
print(df_titanic.columns.values)
```

```
['pclass' 'survived' 'name' 'sex' 'age' 'sibsp' 'parch' 'ticket' 'fare'
 'cabin' 'embarked' 'boat' 'body' 'home.dest']
```

In [6]:
```
df_titanic.head()
```

- -

Machine Learning Begriffe

- Jede Zeile ist eine **observation** (auch genannt: sample, example, instance, record)
- Jede Spalte ist ein **feature** (auch genannt: predictor, attribute, independent variable, input, regressor, covariate)
- Der gesuchte Wert ist die **response** (also known as: target, outcome, label, dependent variable)
- **Klassifikation** wenn die response kategorial ist
- **Regression** wenn die response ein numerischer Wert ist

Jetzt sind wir bereit fürs Modellieren

- Modeling findet im Zusammenspiel mit Data Preperation statt.
- Die Güte des Modells wird mit einer Evaluation gemessen.
- Die meiste Zeit muss in Data Preparation invesiert werden.

In [7]:
```
df_titanic.groupby('pclass').mean()
```

Out[7]:

pclass	survived	age	sibsp	parch	fare	body
1	0.619195	39.159918	0.436533	0.365325	87.508992	162.828571
2	0.429603	29.506705	0.393502	0.368231	21.179196	167.387097
3	0.255289	24.816367	0.568406	0.400564	13.302889	155.818182

Daten visualisieren

In [8]:
```
import seaborn as sns
sns.pointplot(x="pclass", y="survived", hue="sex", data=df_titanic,
              palette={"male": "blue", "female": "pink"},
              markers=["*", "o"], linestyles=["-", "--"]);
```

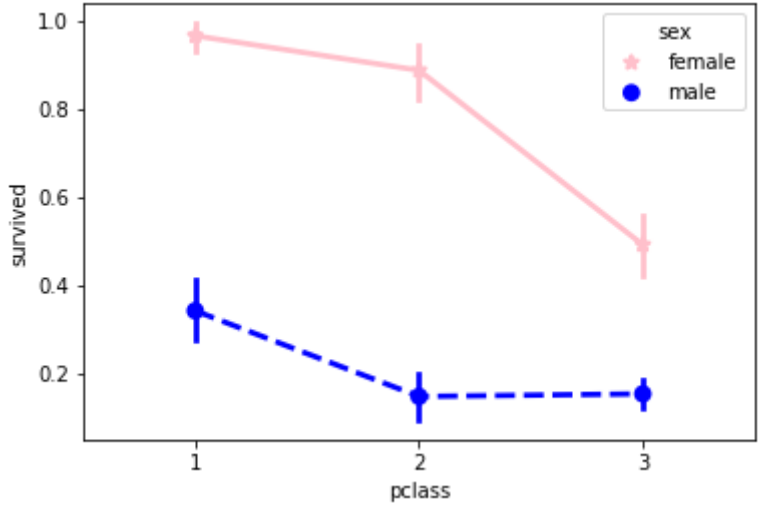

Data preparation

In [9]:
```
# remove some features, for now.
processed_df = df_titanic.drop(['name','ticket','home.dest','embarked', 'sex', 'cabin',
'boat', 'body'], axis=1)
processed_df = processed_df.dropna()


# store feature matrix in "X"
X = processed_df.drop(['survived'], axis=1).values

# store response vector in "y"
y = processed_df['survived'].values


print(X.shape)
print(y.shape)
```

```
(1045, 5)
(1045,)
```

scikit-learn 4-step modeling pattern

Schritt 1: Gewünschte Klass importieren

In [10]:
```
from sklearn.tree import DecisionTreeClassifier
```

Schritt 2: Instanziieren eines "estimator"

- "Estimator" ist scikit-learn's Bezeichnung für Modell

In [11]:
```
dt = DecisionTreeClassifier()
```

Schritt 3: Fitten des Models mit den Daten (aka "model training")

In [12]:
```
dt.fit(X,y)
```

Out[12]:
```
DecisionTreeClassifier(class_weight=None, criterion='gini', max_depth=None,
            max_features=None, max_leaf_nodes=None,
            min_impurity_decrease=0.0, min_impurity_split=None,
            min_samples_leaf=1, min_samples_split=2,
            min_weight_fraction_leaf=0.0, presort=False, random_state=None,
            splitter='best')
```

Schritt 4: Vorhersagen der response für eine neue Observation

- Neue Observationen sind genannt "out-of-sample" data

In [13]:
```
## Hätte ich als Schnäppchenjäger überlebt?
## Liste mit Werten: Ticketklasse, Alter, Eltern, Kinder, Ticketpreis
print(dt.predict([[3, 22, 0,0, 99]]))
```

Doch, wie genau ist diese Aussage?

- Wie korrekt kann das Modell eine Vorhersage machen?
- Wie lassen sich unterschiedliche Modelle mit einander vergleichen?
- Wäre es nicht wichtig, das Geschlecht auch mit zu beachten?

- Evaluation - Data preparation - Data modeling

Evaluation

- Trainieren des Modells auf allen Daten
- Testen des Modells auf den gleichen Daten und prüfen, ob die Vorhersagen stimmen.
- Training accuracy genannt

In [14]:
```
from sklearn import metrics

## Vorhersage speichern
y_pred = dt.predict(X)
## Vergleichen
print(metrics.accuracy_score(y, y_pred))
```

```
0.9636363636363636
```

Probleme dieses Ansatzes?

- Ziel ist es die Performance auf **out-of-sample data** zu messen
- Aber, eine hohe training accuracy führt zu **overly complex models**, welche nicht gut generalisieren können
- Unnötig komplexe Modelle **overfitten** die Trainings Daten.

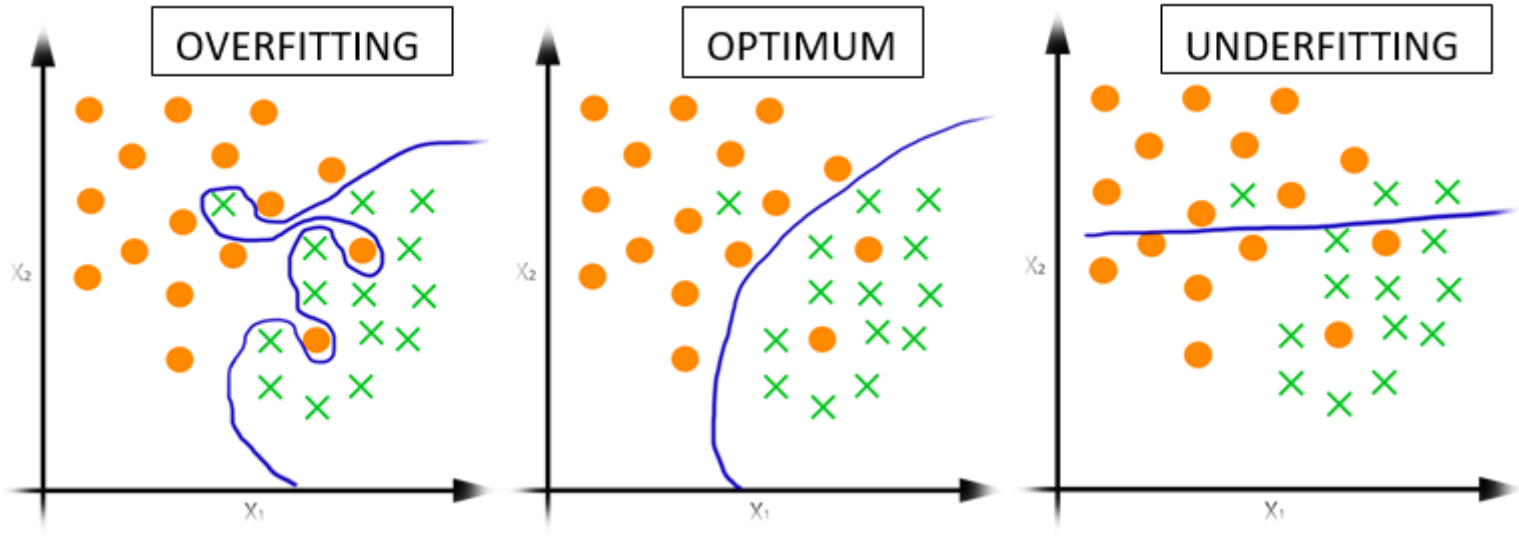

Lösung: Aufteilen der Daten in Test und Training

1. Split der Daten in zwei Teile: ein **training set** und ein **testing set**
2. Trainieren des Modells auf dem **training set**
3. Testen des Modells auf dem **testing set**

Evaluation

In [15]:
```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y)
```

In [16]:
```
dt = DecisionTreeClassifier()
dt.fit(X_train, y_train)
y_pred = dt.predict(X_test)
print(metrics.accuracy_score(y_test, y_pred))
```

```
0.5992366412213741
```

In [17]:
```
# Was wäre die accuracy, wenn immmer "not survived" gewählt wird?

max(y.mean(), 1 - y.mean())
```

Out[17]:
```
0.5913875598086125
```

- Unser Modell ist also erheblich schlechter auf "ungesehenen Daten".
- Wir haben aber auch jede menge Features entfernt.

Ein paar Gedanken zu train/test split

- Je nach Aufteilung des split's wird ein grosser Teil der Daten nicht verwendet.
- **K-fold cross-validation** eliminiert dieses Problem.
- Aber, train/test split ist trotzdem nützlich durch seine **Flexibilität und Geschwindigkeit**

Wie funktioniert cross-validation?

1. Splitten der Daten in K **gleiche** Partitionen (oder "folds").
2. Benütze den ersten fold als **testing set** and alle restlichen als **training set**.
3. Berechne **testing accuracy**.
4. Wiederhole die Schritte 2 und 3 K-Mal, immer mit einem anderen fold.
5. Der Durchschnitt aller ergibt die **average testing accuracy**.

5-fold cross-validation:

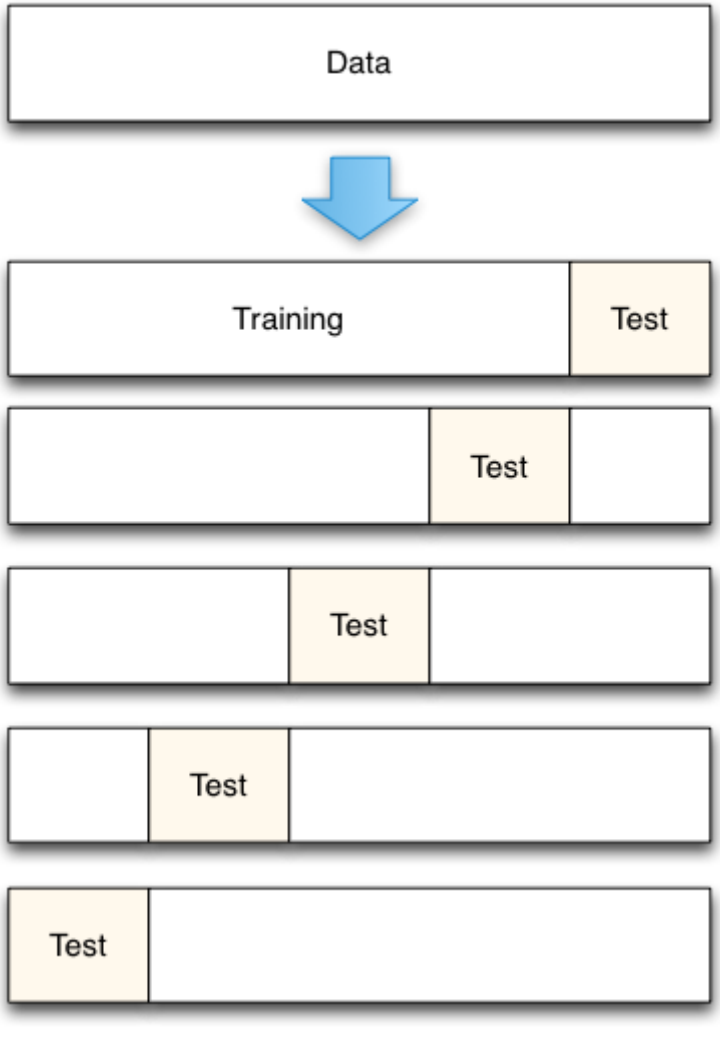

cross-validation

In [18]:
```
from sklearn.model_selection import cross_val_score

dt = DecisionTreeClassifier()
scores = cross_val_score(dt, X, y, cv=10, scoring='accuracy')
print(scores)
```

```
[0.48571429 0.59047619 0.55238095 0.53333333 0.60952381 0.61904762
 0.56190476 0.55769231 0.53398058 0.61165049]
```

In [19]:
```
print(scores,res.mean())
```

```
0.5655704328034427
```

Zurück zu Data preparation

- Das Modell ist nur knapp besser als eine Münze zu werfen.
- Wir haben wichtige Features weggelassen (Alter und Geschlecht).

In [20]:
```
# wir entfernen weiterhin einige features
processed_df = df_titanic.drop(['name','ticket','home.dest','embarked', 'cabin', 'boat',
```

Ansicht Beispieldaten

In [21]:
```
processed_df.sample(5)
```

Out[21]:

	pclass	survived	sex	age	sibsp	parch	fare
820	3	1	1	9.000000	0	2	20.5250
538	2	1	1	30.000000	0	0	12.7375
410	2	0	1	29.881135	0	0	0.0000
600	3	0	1	42.000000	0	0	7.5500
371	2	1	0	45.000000	0	2	30.0000

Evaluation

In [22]:
```
dt = DecisionTreeClassifier()
scores = cross_val_score(dt, X, y, cv=10, scoring='accuracy')
print(scores.mean())
```

```
0.7147798003523194
```

In [23]:
```
from sklearn.ensemble import RandomForestClassifier
rf = RandomForestClassifier()
scores = cross_val_score(rf, X, y, cv=10, scoring='accuracy')
print(scores.mean())
```

```
0.7461009982384029
```

Evaluation

In [24]:
```
from sklearn.linear_model import LogisticRegression
logreg = LogisticRegression()
scores = cross_val_score(logreg, X, y, cv=10, scoring='accuracy')
print(scores.mean())
```

```
0.7644744568408691
```

In [25]:
```
from sklearn.neural_network import MLPClassifier
clf = MLPClassifier(activation = 'relu', solver='lbfgs', hidden_layer_sizes=(150))
scores = cross_val_score(clf, X, y, cv=10, scoring='accuracy')
print(scores.mean())
```

```
0.7492190252495596
```

Welche Modelle gibt es sonst noch?

… und welche davon soll ich testen?

- einige
- kommt drauf an

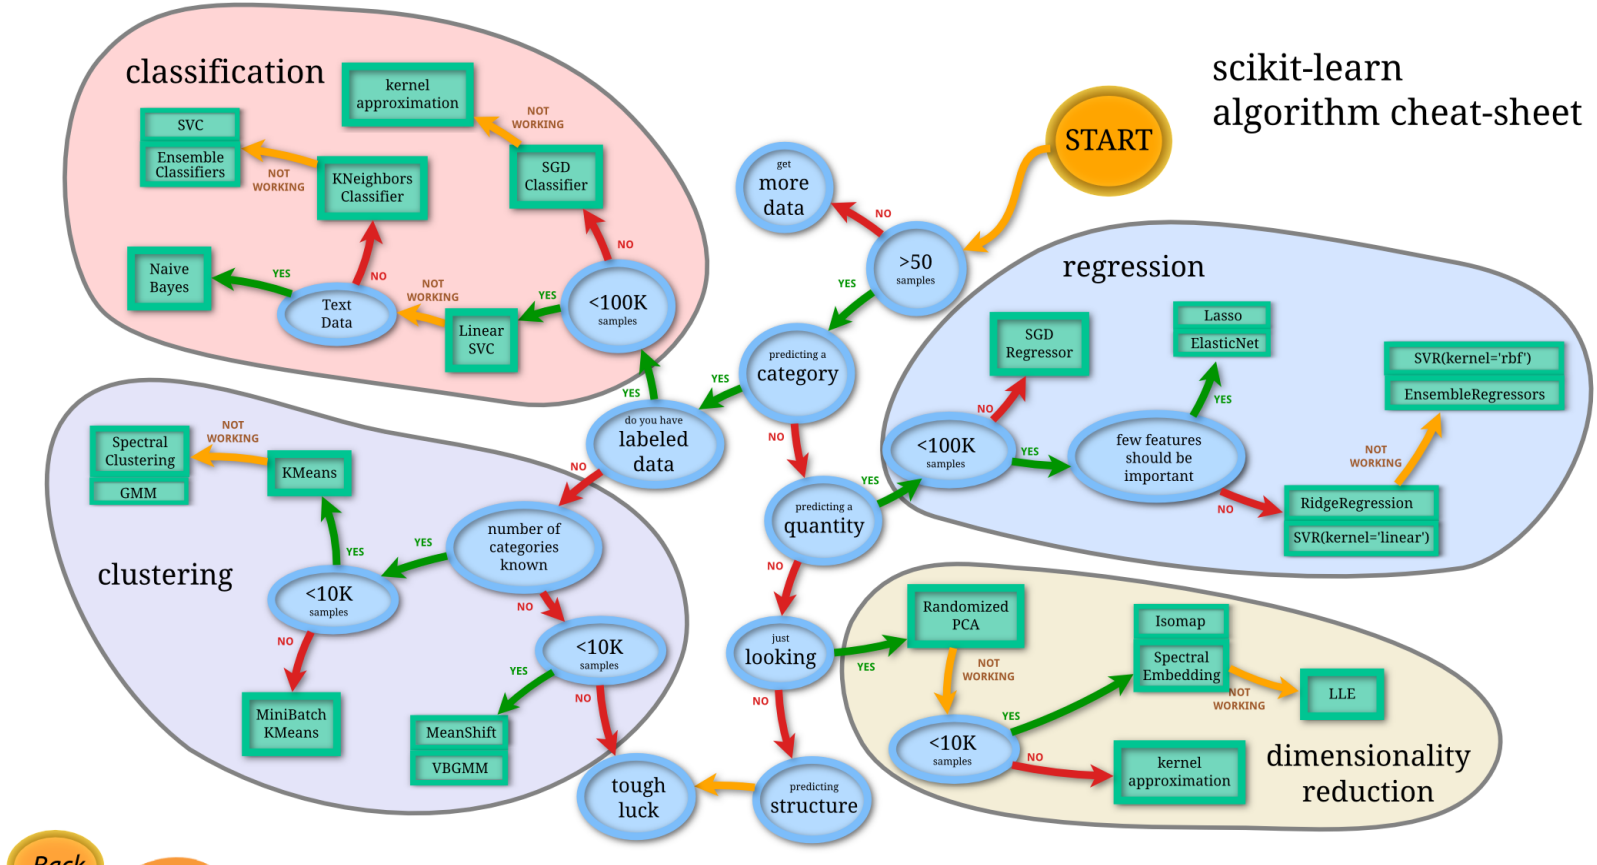
scikit-learn
algorithm cheat-sheet
START
>50 samples
get more data
predicting a category
predicting a quantity
just looking
predicting structure
do you have labeled data
<100K samples
Linear SVC
Text Data
Naive Bayes
KNeighbors Classifier
SVC
Ensemble Classifiers
SGD Classifier
kernel approximation
NOT WORKING
YES
NO
classification
<100K samples
few features should be important
SGD Regressor
Lasso
ElasticNet
RidgeRegression
SVR(kernel='linear')
SVR(kernel='rbf')
EnsembleRegressors
regression
number of categories known
<10K samples
KMeans
Spectral Clustering
GMM
MiniBatch KMeans
MeanShift
VBGMM
clustering
Randomized PCA
Isomap
Spectral Embedding
LLE
kernel approximation
dimensionality reduction
tough luck
Back
scikit learn

Je nach Problem / Daten

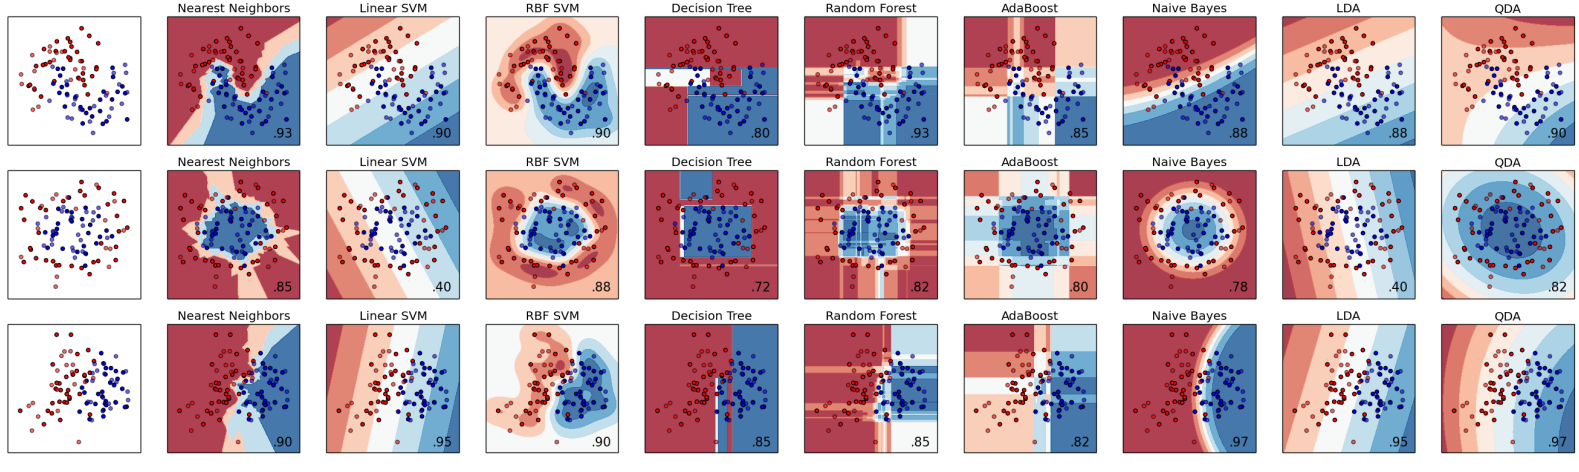

Liste durchprobieren

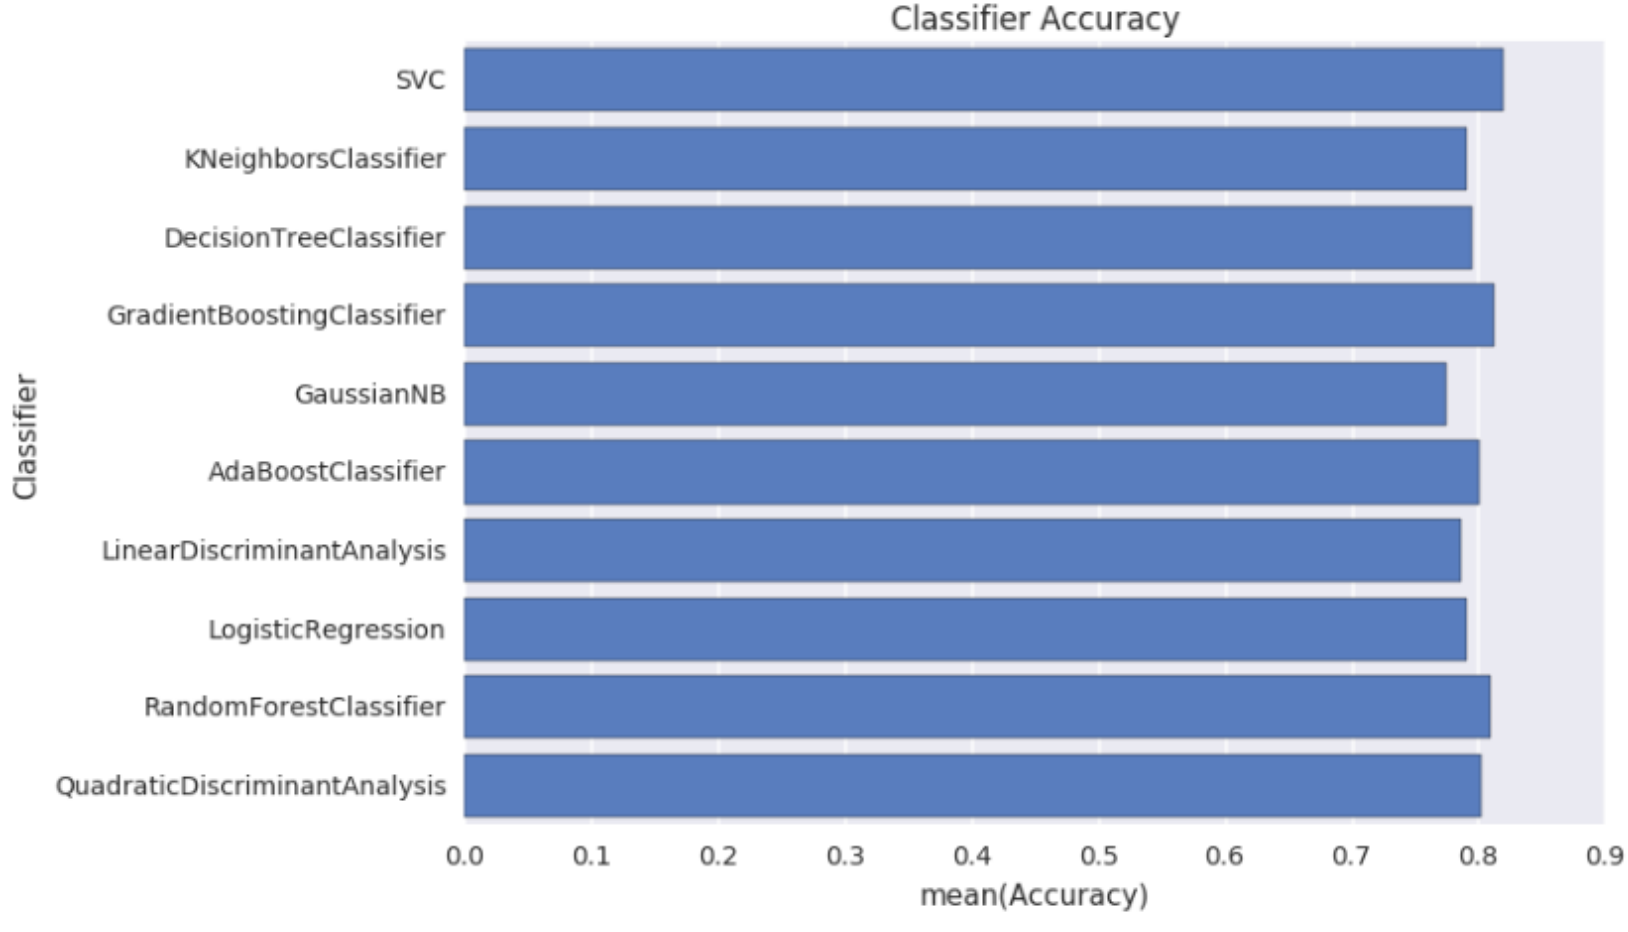

Welcher nun?

- Data preparation

Weiterführende Themen:

- Modell Bewertungsmöglichkeiten: Precision and Recall, ROC
- Grid-Search zum finden von optimalen Modellparametern
- Deploy: **Dabbawala Analytics Modul** - Modelle verwalten

Kaggle Competitions

In [ ]:
```
IFrame('https://www.kaggle.com/c/titanic', width=1200, height=800)
```

Wrap up

- Artificial Intelligence - Machine Learning - Deep Learning
- Supervised Learning (Classification, Regression) - Unsupervised Learning (Clustering)
- python - scikit-learn - jupyter notebooks (https://github.com/bravenoob/machine-learning (https://github.com/bravenoob/machine-learning))
- CRISP-DM
- Training set, testing set, overfitting, underfitting, cross-validation
- Dabbawala Analytics Modul Link Wiki (https://confluence.bedag.ch/display/DAB/Analytics+Modul)
- Analytics Komitee Link Wiki (https://confluence.se.bedag.ch/display/BDS/SE+Analytics)

Fragen?